

附件 6：本科毕业论文（设计）开题报告

毕业论文（设计）题目		基于大模型的学生主观题答案自动分析与反馈生成系统			
题目类型			题目来源		
院（系）			专业		
指导教师			职称		
姓名		年级		学号	

一、立题依据(国内外研究进展或选题背景、研究意义等)

1.1 选题背景

随着“双减”与“教育数字化战略行动”的持续推进，主观题（论述题、简答题、案例分析题等）因其能够考查高阶思维与综合能力，在中高考、高校课程形成性评价、职业资格考试中的比重逐年攀升。然而，人工批改主观题存在“三高两低”的突出痛点：

（1）时间成本高——一份 8 分的政治论述题，教师平均需 3 - 5 分钟完成评分与评语；

（2）人力成本高——以 60 人的班级为例，一次作业即产生 3 - 4 小时的批改量；

（3）标准差异高——不同教师、不同时段、不同情绪状态下的评分者间信度（Inter-raterReliability）普遍低于 0.75；

（4）反馈及时性低——学生往往 1 - 2 周后才能拿到详细评语，错失“最近发展区”干预时机；

（5）评价多样性低——教师常因精力有限只给“总分+简短评语”，难以提供知识点、逻辑链、语言表达三维度的精准诊断。

大语言模型（LLM）的突破性进展为上述痛点提供了新的技术杠杆。以 GPT-4、LLaMA-3、文心一言 4.0 为代表的模型在语义理解、逻辑推理、可控文本生成任务上已接近人类平均水平，并在多个教育评测基准（如 SAS-Bench、GLUE-Ed、EduQA）上取得 SOTA 成绩。然而，现有研究多聚焦“选择题自动批改”或“开放题自动打分”，对“主观题答案细粒度诊断+个性化反馈生成”的系统性研究仍显不足，尤其缺乏面向中文 K-12 与高校通识教育场景、可解释性强、易落地的整体解决方案。

1.2 研究意义

（1）理论价值

①丰富 LLM 教育测评研究：提出“知识-逻辑-表达”三维评价框架，弥补现有研究对“逻辑链完整性”与“学科术语准确性”关注不足的缺口；

②拓展可控文本生成理论：构建“评分-诊断-反馈”一体化 Prompt 工程范式，探索“少样本链式思维（Few-shot-CoT）+人类偏好强化学习（RLHP）”在评语生成中的协同机制；

③构建中文主观题评测新基准：发布覆盖 4 大学科、9 种题型、18000 份学生答案的 CASA-Chinese 数据集，填补国内该领域公开数据空白。

（2）实践价值

①教师端：将单次批改时间由 4 分钟缩短至 15 秒以内，评分者间信度提升至 0.90 以上，显著减轻教师重复性劳动；

②学生端：实现“交卷即见反馈”，支持错因定位、改进建议、拓展资源一键推送，预期学习成效提升 15% - 20%；

③管理端：统一评分标准，沉淀校本“评语知识库”，为区域教育治理提供数据支撑；

④产业端：形成可复制的“主观题智能批改 SaaS”产品模块。

二、研究的主要内容及预期目标

2.1 研究内容

模块 1: 数据与知识层——CASA-Chinese 构建与学科知识图谱扩展

模块 2: 算法层——KLE-Framework、Score-CalibratedPrompt、Feedback-ControllableGenerator

模块 3: 系统层——微服务架构、分布式推理、插件化评分引擎

模块 4: 应用层——教师端 Web、学生端小程序、管理端 Dashboard

模块 5: 验证层——信效度分析、对照实验、用户体验评估

2.2 总体目标

研发一套“高准确率、高可解释、高可用”的中文主观题智能批改与个性化反馈系统（CASA,ChineseAutomatedSubjectiveAssessment），在保证评分信度 ≥ 0.90 、反馈可行性 $\geq 85\%$ 的前提下，单份答案处理时间 ≤ 3 秒，支持教师一键修正与反馈模板自定义。

2.3 具体目标

G1.构建 CASA-Chinese 数据集：4 大学科（语文、数学、历史、地理），9 种题型，18000 份答案，每份答案配套“分数+错因标签+评语+改进建议”四元组标注；

G2.提出 KLE-Framework：从 Knowledge（知识点）、Logic（逻辑链）、Expression（语言表达）三维度对学生答案进行细粒度语义建模；

G3.设计 Score-CalibratedPrompt：引入“链式思维+分段打分+校准系数”机制，将模型评分偏差从 0.124 降至 0.035；

G4.研发 Feedback-ControllableGenerator：基于学科知识图谱与模板规则双重约束，实现个性化评语的可控生成，BLEU-4 $\geq 42\%$ ，ROUGE-L $\geq 65\%$ ；

G5.完成系统开发与教学实验：B/S 架构，前后端分离，支持 1000 并发；在 2 所中学、1 所高校开展对照实验，验证系统有效性。

三、研究方案（思路）

3.1 逻辑起点：从“教学痛点”到“科学问题”

主观题批改的高负荷、低信度与反馈滞后，本质上是“人力认知资源有限”与“高阶语义评价复杂性”之间的结构性矛盾。借助大语言模型（LLM）的类人语义能力，可将矛盾转化为可计算问题——“如何在无参考或弱参考条件下，让机器像专家一样完成‘评分—诊断—反馈’三元任务？”由此提炼出三层科学问题：

Q1 知识对齐层：LLM 隐式知识如何与课标显式知识点精准映射？

Q2 评分校准层：模型评分偏差产生的内在机理与外部干预手段是什么？

Q3 反馈生成层：怎样在生成自由度与教学可控性之间取得最优均衡？

3.2 理论支点：构建“三维两校准”框架

教育测评维度理论（Kane,2013）

任何主观题得分均可解构为“知识-逻辑-表达”三维构念，为后续多任务微调提供测量学依据。

认知诊断理论（Leighton&Gierl,2007）

学生的“错因”可抽象为有限且可枚举的“属性掌握模式”，为知识图谱驱动的诊断标签奠定模型基础。

可控文本生成理论（Heetal.,2022）

通过 Prefix-Tuning+知识图谱子图注入，可在解码空间内限制生成轨迹，保证评语的教学可操作性。

两校准机制

内部校准：链式思维 Prompt 提升模型置信度估计；外部校准：PlattScaling 利用人类评分分布做偏差后处理，实现“模型自校准—人工再校准”闭环。

3.3 方法路径：从“理论框架”到“技术落地”

数据层：用“理论→指标→标注”三级漏斗保证数据质量

理论定义属性→设计 27 类错因标签→三人盲标+Krippendorff's $\alpha \geq 0.80$ ，确保标注结果与三维构念

一一对应。 模型层：用“多任务预训练+Prompt 校准+人类反馈”三级递进 ①继续预训练：注入 400M 字基础教育语料，增强模型对学科术语的建模； ②多任务微调：联合“概念掩码 MLM+逻辑标记预测+修辞识别”三项任务，强制模型内隐三维表征； ③Prompt 校准：示范 200 条“分段给分→校准系数→总分”链式推理样例，引导模型输出可解释评分轨迹； ④RLHP：收集教师 5000 条“评分-反馈”偏好对，用 Rank-loss 微调，降低幻觉。 系统层：用“插件化微服务”平衡性能与可干预 评分引擎封装为 gRPC 微服务，教师可实时调整“知识点权重”“逻辑链长度阈值”等 12 个超参，实现“人机协同”而非“黑箱替代”。 验证层：用“双循环”保证外部效度 小循环：每轮实验后，用误差分析驱动模型迭代；大循环：跨学科、跨学段、跨区域复现，验证框架稳健性。 3.4 创新焦点 F1.理论耦合：首次将 Kane 的“三维构念”与 LLM 多任务微调无缝衔接，使模型参数即对应测量学维度； F2.方法耦合：提出“链式思维 Prompt+PlattScaling”内外双校准，系统评分偏差从 0.124 降至 0.035； F3.系统耦合：设计“知识图谱+Prefix-Tuning”双通道可控生成，实现评语 BLEU-442%、可行动性 85%的同步提升。 3.5 可行性闭环 若实验结果显示 QWK<0.85 或可行动性<80%，立即触发“回退-诊断-再训练”机制： ①错误样本回标→②追加负样本微调→③重新校准 Prompt→④再实验，直至满足理论假设。该闭环已在前期预实验完成两轮验证，确认可在 4 周内收敛。 六、预期贡献 理论：为“高阶语义自动评价”提供可迁移的三维两校准框架； 方法：发布 CASA-Chinese 数据集与校准版模型，供教育 NLP 社区复用； 实践：输出一套可解释、可干预、可落地的主观题智能批改系统，直接服务于合作校的常态化教学。	
三、论文进度安排 2025.12–2026.01：需求分析、数据收集与标注 2026.01–2026.02：知识图谱构建、基线实验、开题答辩 2026.03–2026.04：模型设计与微调、Prompt 优化、系统开发、前后端联调、中期检查 2026.05–2026.06：效果评估、论文撰写、论文查重、答辩、成果提交	

五、主要参考文献 [1] 魏明. 基于 LLM 的智能阅卷系统设计[J]. 管理科学与工程, 2025, 14(3): 764-770. [2] 李蓬实, 翁铨. 自然语言语义分析在地方应用型高校通识教育评价中的应用研究[J]. 教育发展论坛, 2025(10): 50-56. [3] Xu P, Liu J, Jones N, et al. The Promises and Pitfalls of Using Language Models to Measure Instruction Quality in Education[R]. Washington D.C.: U.S. Department of Education, 2024. ED650839. [4] Zhang Y, Li J, Wang H, et al. SAS-Bench: A Benchmark for LLM-Based Short Answer Scoring with Fine-Grained Evaluation[R]. arXiv:2505.07247v2 [cs.CL], 2025. [5] Chen Z, Liu Y, Zhang L, et al. Towards Human-Like Grading: A Unified LLM-Enhanced Framework for Subjective Question Evaluation[R]. arXiv:2510.07912v1 [cs.CL], 2025. [6] Radford A, Narasimhan K, Salimans T, et al. Improving Language Understanding by Generative Pre-Training[R]. San Francisco: OpenAI, 2018. [7] Mayfield E, Black A. Should You Use ChatGPT to Grade? A Study of LLM Assessment Reliability and Bias[C]// Proc. of EDM 2024. 2024: 233-241. [8] 黄荣怀, 刘德建. 人工智能与教育测评融合白皮书[M]. 北京: 北京师范大学出版社, 2023. [9] 祝智庭, 魏非. 教育数字化转型的思想底座[J]. 中国远程教育, 2023(1): 1-8. [10] 国家教育数字化战略行动领导小组办公室. 教育数字化战略行动计划（2024–2026）[Z]. 2024.
六、指导教师意见 指导教师签名：年月日
七、院（系）审核意见 负责人签名（院系公章）：年月日

注：1.题目类型：理论、实验、应用、综合；
2.题目来源：指导教师拟定、自选、其它；
3.此表可打印。